
Face Recognition Benchmark: internal release vs. commercial solutions

人脸识别基准：内部版本vs. 商业方案

Internal Reference Only 仅供内部参阅

inlmouse*

Glasssix Research

成都, 610051

inlmouse@glasssix.com

边凯凯†

Glasssix Research

成都, 610051

bkk@glasssix.com

Abstract

为了评价人脸识别算法的性能，我们建立此基准用于比较公司内部的模型版本，竞争对手的商用模型以及学术领域的开放模型。

1 基准细节

这个部分总结了人脸识别在多个基准上评价的结果。注意LFW 和YTF 评价协议依照我们的设计原则而来，也就是说它们的结果不能和发表的相比较。

1.1 基础信息

为了标记简单，我们采用以下的记号：

- D: 数码相机
- W: 网络搜集
- M: 手机摄像头
- S: 监控摄像头
- I: 身份证读卡器

1.2 细节

- **LFW(弃用):** 开放数据集；
- **YTF(弃用):** 开放数据集；每帧来源于YouTube, 大约20% 的人脸非常模糊；
- **UOFW:** 所有图片来源于户外拍摄的监控摄像头；

*最后修改于-。

†最后修改于 2019 年 1 月 3 日。

表 1: 基准细节

基准	人种	图片	大小(P/N)	来源	姿势	光照
弃用						
LFW	国际	13233	3000/3000	W	难	易
YTF	国际	624209	2500/2500	D	难	易
Now Concerned						
UOFW	中国人	8908	2268/2185	S	难	难
Bing	中国人	20021	10000/10000	M	中	中
MSRMV	中国人	532	784/10000	D & S	难	易
1V1	中国人	1244	797/5000	D & I	易	易
SS	中国人	31525	10000/10000	D & I	中	易
XKX	中国人	18249	5000/5000	D	中	中
KTP	中国人	17007	100000/100000	D&I&W	中	难

- **Bing:** 所有图片来源于Bing 直播画面；
- **MSRMV:** 一个多视角的基准，每个人有1/2 的高清前脸图片，从视频中选取28帧，这样每个人在4个不同的距离,有7个不同的头部姿势；只在高清图片和28帧图像间进行配对；
- **1V1:** UNCD¹，BBXL² 和其它网络搜集数据的结合；在身份证和照片之间产生验证对；
- **SS:** 社会安全场景；每人有一张身份证读取的照片，以及2~5 张摄像头拍摄的照片，10% 拍摄的照片条件和质量都很差；数据集中人的年纪均在55岁上下；
- **XKX:** 智能手机直播场景；所有的数据来源于小咖秀³；由于该手机软件的特殊用途，每个人的照片偏差要远远大于Bing 里的照片；
- **KTP:** 所有的照片来源于户外拍摄，前脸。监控摄像头，USB 摄像头和身份证阅读器；

2 模型总结

这一部分简要地讲解模型是如何被构建的。一个很重要的指标是FLOPs(浮点运算) 的数量，它真实地反应CNN 网络在特定设备（CPU 或GPU）上前向的时间。为了计算FLOPs，我们假设卷积操作是用一个滑动窗实现的，而且非线性函数的计算是零。对于卷积核，我

¹手持身份证拍照，既有真人的人脸也有身份证照片

²此数据集和UNCD 数据集为不合法采集。数据来源受保护。

³www.xiaokaxiu.com

们有

$$FLOPs = 2HW(C_{in}K^2 + 1)C_{out}/G \quad (1)$$

这里 H, W 和 C_{in} 代表了高度, 宽度, 以及输入特征图的通道个数, G 是群组的个数, K 是卷积核大小 (假定为对称的), C_{out} 是输出通道的个数。

对于全连接层, 我们计算FLOPs 如下:

$$FLOPs = (2I - 1)O \quad (2)$$

这里 I 是输入的维度, O 是输出的维度。

和卷积层类似, 池化层可被认为是一个无参数的卷积层。一次加法运算或比较运算消耗的计算量约为浮点加-乘的1/8。所以我们计算FLOPs (最大池化是比较运算的 N 倍, 平均池化是 N 倍的比较运算加1个除法运算, 它可以近似看作 $N/8$ 倍的加-乘运算) 如下:

$$FLOPs = 2HW(C_{in}K^2 + 1)C_{out}/G/8 \quad (3)$$

这里, 符号和卷积层计算中的一样。

对于(P)ReLU 或其它按元素的操作, 我们都将之认为是特征图中逐个元素的乘法运算, 所以FLOPs 等于特征图的维度:

$$FLOPs = I * N \quad (4)$$

I 是输入的维度, N 是Eltwise 层输入的个数减去1。对于(P)ReLU, $N = 1$ 。

注意一些开放模型的总结来源于其作者的描述, 它们可能是不完备的或不正确的。

表 2: 当前所使用模型的一些细节

模型(输入大小)	GFlops	MParams	模型大小(MB)	特征大小(MB)
目前预发布版本				
mobile_unicorn(128*128)	0.58	12.96	3.99	N/A
unicorn(128*128)	7.31	24.64	94.00	N/A
unicorn_uc(128*128)	18.58	38.21	154.00	N/A
unicorn_se(128*128)	8.72	24.79	94.60	N/A
unicorn_li(128*128)	1.97	6.43	25.70	N/A
unicorn_fc(128*128)	7.44	27.68	110.70	N/A
供参考的开放模型				
GoogleNet(224*224)	2.0	12.75	51.0	26
Inception V3(224*224)	5.00	23.20	92.8	89
AlexNet(227*227)	0.72	60	240	3
SqueezeNet(224*224)	0.36	0.75	3	17
VGG16(224*224)	16	132	528	58
ResNet51(224*224)	4	24.5	98	103
ResNet101(224*224)	8	42.5	170	155
ResNet151(224*224)	11	57.5	230	219

为了方便，我们将一些常用的CPU和GPU的算力放在下面展示：⁴：

表 3: 一些常用的CPU和GPU的算力

产品	类别	GFlops/s	Boost Clock(GHz)	储存 带宽(GB/s)	核 个数
Intel i7-6700K	CPU	113.53	4.2	34.1	4
Intel i7-7820X	CPU	178.13	4.5	–	8
Nvidia TitanX(Maxwell)	GPU	6691	1.089	336.6	3072
S5P G6818	ARM	–	1.4	–	8
Nvidia GTX-1060	GPU	4375	1.709	192.2	1280
Nvidia GTX-1080	GPU	8873	1.733	320.3	2560
AMD RX-Vega-56	GPU	10556	1.474	409.6	3584
Nvidia GTX-1080Ti	GPU	11340	1.582	484.4	3584
Nvidia TitanX(Pascal)	GPU	10974	1.531	480.4	3584
Nvidia TitanV	GPU	14899	1.455	652.8	5120

技术上，理论前向时间等于模型FLOPs / 设备GFlops/s。但是，理论速度从未达到过。由于不同的时钟频率，带宽和未完全利用的核，实际速度只能达到1/5（这也是一个经验值）的理论速度。

3 通用测试协议

3.1 验证基准：TAR@FAR (%)

TAR@FAR 测试的细节可在https://en.wikipedia.org/wiki/Confusion_matrix上找到。

一些符号在下面做介绍⁵。

为了让基准更具有说服力，一些数据集中的样本对被人工微调了：如果一张照片包括身份证照片，我们就选取这张照片。没有随机选取负样本对，我们确定在不同样本对之间没有重复的照片。同时，我们必须承认商用的SDK可能不会达到它们最好的性能：因为所有的数据集都是用我们自己的检测器检测的，我们发现2–3%的照片没有识别到任何的人脸。这样的话，我们就将这一整个样本对看作假负样本对。这个操作可能造成商用SDK性能上的差异。

3.2 珍爱网的Mega 验证基准TAR@FAR (%)

为了在一个更严格的场景中评价我们的模型，我们从珍爱网⁶上选取了大量的数据，选取了110,448个人和340,542张照片来作为一个1:1的基准。平均每个人有3.08张照片。正

⁴所有的数据来源于https://asteroidsathome.net/boinc/cpu_list.php和<https://www.techpowerup.com/gpudb/>。

⁵*: 以"F"结尾的数据集的意思是，它是原来数据集中的子数据集，照片都是仅有前脸的。它们中的绝大多数都是严格的身份证照片和照相机拍摄的照片。

⁶www.zhenai.com

表 4: 验证基准: TAR@FAR=1e-3

模型	XKX	1V1F*	SSF*	UOFW	Bing	1V1	MSRMV	SS
目前发布的版本								
mobile_unicorn9230	81.96	78.31	74.76	37.08	89.24	70.60	52.14	76.40
mobile_unicorn9138	78.60	74.40	77.64	38.07	86.04	75.66	46.00	72.55
mobile_unicorn9040	67.92	71.80	76.22	41.60	85.86	72.21	30.76	71.15
unicorn9734	98.26	97.40	96.41	40.25	97.80	95.45	81.32	94.21
unicorn9722	98.54	96.53	96.63	34.06	97.68	95.38	77.68	94.20
unicorn9699	98.42	96.53	96.08	53.35	97.30	94.72	76.18	93.19
unicorn9691	97.16	95.28	94.54	57.15	97.06	94.65	80.56	92.62
unicorn9583	97.96	94.42	92.86	56.79	97.16	93.03	70.26	92.64
unicorn9560	91.46	91.85	90.38	53.15	96.42	92.37	79.42	89.80
unicorn9570	89.78	92.06	89.20	54.23	96.16	93.33	66.30	89.38
unicorn9490_pca	N/A	94.21	90.36	N/A	95.62	92.89	64.84	89.88
unicorn_fc_9275	N/A	92.92	91.40	N/A	95.30	92.52	49.08	89.74
unicorn9490	86.48	94.85	90.12	46.65	95.68	92.74	63.82	90.40
unicorn_se_9199	85.26	90.77	84.54	22.03	95.44	90.54	68.60	86.26
unicorn9304_pca	N/A	89.48	90.17	N/A	95.82	90.17	72.42	87.62
unicorn_uc_9201	N/A	73.82	45.40	18.06	95.20	74.05	72.28	58.08
unicorn9304	N/A	88.41	87.36	54.60	95.76	89.88	71.64	87.34
unicorn_li_9493	95.82	93.78	89.76	64.69	95.32	88.56	63.40	89.04
unicorn9277	76.48	83.48	75.06	42.02	90.84	83.58	44.46	84.12
商用SDKs								
dilu	N/A	N/A	N/A	11.90	67.99	62.76	17.60	60.65
cloudwalk	N/A	96.78	91.78	16.44	89.62	N/A	46.12	87.92
face++	N/A	90.99	92.34	20.34	96.26	94.06	52.29	91.72
youtu(2015)	N/A	50.72	37.64	18.36	46.46	46.41	16.76	37.76
baidu(2018)	78.00	92.27	72.92	18.91	92.74	87.02	32.86	69.42
youtu(2017)	63.25	70.39	47.96	16.76	84.78	N/A	37.22	N/A
arcsoft	N/A	87.55	67.32	21.68	83.04	83.94	12.00	68.46

负样本的比例是320,816 / 1,104,898.

我们依据下面的原则来选择负样本: 先建立一个名字列表, 然后在它里面循环11次, 间隔为2到12。随机选择每个人的一张照片作为负样本对中的一个。通过这个方法, 我们几乎可以确保每个样本对中有2个不同的人。

我们将数据在下方呈现:

表 5: 珍爱网的Mega 验证基准: TAR@FAR=1e-1~ 1e-6

模型	1e-1	1e-2	1e-3	1e-4	1e-5	1e-6
当前发布的版本						
unicorn9722	98.74	97.96	96.36	92.92	87.09	75.58
unicorn9691	98.71	97.65	95.51	91.28	83.28	70.65
unicorn_RX0_9691	98.22	97.99	96.42	93.39	87.78	72.10
unicorn9583	98.66	97.53	94.75	89.66	83.07	75.47
unicorn9490	98.55	96.93	93.71	88.65	80.28	73.65
unicorn9304	98.62	97.12	94.23	89.65	80.51	73.97
unicorn9217	98.52	96.16	92.05	85.11	74.17	68.21
unicorn_li_9493	98.53	96.57	92.48	86.12	77.32	69.34
unicorn7164	93.71	82.25	68.26	55.96	43.23	34.99




图 1: 人脸识别和验证性能。有趣的是, 这些算法在用户测试的非标准库上都比较稳定, 但在公认的标准库上算法的性能则会下降。

我们成功找到了错误样本对。大多数的假正样本多少都是由于图片模糊和图片太小。注意所有的算法都在LFW 上获得超过99% 的准确率, 但是, 不同模型间的差异会通过1e-6 TAR@FAR 放大出来。一个简单小型的基准不可能通过准确而客观的评价标准来描述一个模型。

同时, 我们发现Probe-Gallery 测试方法, 例如MegaFace⁷, 无法反映模型或算法的真实情况。如果一个Probe 数据集远远小于Gallery 数据集, 结果会被其它东西影响。同一个模型

⁷<http://megaface.cs.washington.edu/index.html>

如果使用了不同的人脸对齐方法，将产生无法忽视的影响。当然，这些小的Probe set 很容易就会过拟合。同时，如果Probe set 非常大，消耗的时间也是无法接受的。

4 特定条件下的测试协议

4.1 跨年龄验证

为了进一步观察人脸识别中年龄变化的影响，我们在AgeDB 上给出了识别的结果。我们在AgeDB 最终版本的一个子集上进行的实验，AgeDB 在开放后又进一步被扩展了。⁸



图 2: AgeDB 中年龄差距为30岁的正样本对。在这个时间跨度内面部样貌变化很大。

AgeDB 是一个in-the-wild 数据集，在姿势，表情，光照，和年龄上有着很大的差异。AgeDB 包括12,240 张照片，属于440 个不同的人，如演员，作家，科学家，政客等。每张照片依据它的身份，年龄，以及性别属性进行标注。最小和最大的年龄分别为3岁和101岁。这些人的平均年龄为49岁。测试数据根据年龄差距分为4个组（5岁，10岁，20岁，和30岁）。每个组有10小组人脸照片，每小组包含300个正样本以及300个负样本。人脸验证评价指标和LFW 中的是一样的。在表6, 我们将我们的模型版本和基线模型进行比较：Marginal Loss, VGG Face 和Center Loss。随着年龄差距增大，所有的方法都能看到明显的性能下降，这表明年龄变化仍然是非常具有挑战难度的，尤其是当年龄的差距大于30岁。图4.1 显示了子数据集中的一些正样本对，年龄差距在30岁。由于面部样貌巨大的变化，在这个数据集上进行人脸验证非常具有挑战性。

同时，我们在表7 呈现了TAR@FAR(%) 为 $1e-3$ 的情况。显然，准确率越接近，表明模型越稳定。

⁸<https://ibug.doc.ic.ac.uk/resources/agedb/>

表 6: AgeDB 验证基准: 准确率

模型	5 岁差距	10 岁差距	20 岁差距	30 岁差距
目前发布的版本				
unicorn9722	98.14	98.15	97.34	96.43
unicorn9699	98.12	98.06	97.29	96.37
unicorn9691	97.96	97.98	97.17	95.85
unicorn9583	96.61	96.33	94.81	92.60
unicorn9490	96.34	96.05	94.92	91.75
unicorn_uc_9132	96.41	96.21	94.53	92.58
开放模型				
Marginal Loss	98.12	97.95	97.15	95.75
Center Loss	95.93	95.15	93.07	90.72
VGG Face	93.15	92.18	89.15	85.08

表 7: AgeDB 验证基准: $TAR@FAR(\%)=1e-3$

模型	5 岁差距	10 岁差距	20 岁差距	30 岁差距
unicorn9722	93.61	92.98	92.13	85.28
unicorn9699	94.54	92.55	90.33	83.83
unicorn9691	93.75	92.73	86.37	81.13
unicorn9583	85.71	83.96	61.81	47.31
unicorn9490	83.96	76.61	70.76	37.27
unicorn_uc_9132	77.17	72.94	69.83	38.43

4.2 复杂光照（照明）条件下的验证

在Oriental Face Database Illumination Database(OFID)⁹数据集上, 我们使用3个独立的光源(D0-D2, 光源来自正前方, 左边, 右边)的开闭组合来产生8个不同的照明效果。单个摄像头(C9-1)被放置在人脸的正前方用于拍摄。一些样本照片在图4.2中展示。

我们先从简单的开始, 如表8所示, 将光源(LS)工作状态设为 $D_i = 1$, 否则为0。所以 $(D_2 D_1 D_0)_2 = (111)_2 = 7$ 可被视作锚定图像, 因为它的照明条件是充分而均衡的。将余弦相似度和其它的条件进行比较, 找出每种光源产生的影响。

在所有人的 $(111)_2$ 种照明情况之中, 计算彼此的余弦相似度 $(000)_2 \sim (110)_2$, 列出平均值(如表9), 以及相似度数组的标准方差。

⁹<http://gr.xjtu.edu.cn/web/jianyi/english-version>




图 3: Illumination sample.

表 8: 照明条件的一些细节

$(D_2 D_1 D_0)_2$	000	001	010	011	100	101	110	111
LS 方向	N/A	右边	正前方	半右方	左边	左-右	半左方	全部

和Megabench一样，我们在10中列出OFID₁₀上的验证基准，来评价不同光照条件带来的影响。我们使用所有的34,916个正样本对，然后构建同样数量的负样本对。

4.3 多角度头部姿势验证

在Oriental Face Database Viewpoint Database(OFVD)¹⁰数据集中，每个人都被要求看向摄像头(C9)的中间位置，通过调节椅子保证每个人的眼睛高度是1.3米。19张照片是通过多角度CCD/数码相机系统拍摄完成，每10度拍摄一张照片。角度子数据集中的一些例子可参考图4.3。




图 4: 多角度示例

我们制作了12470个正样本对和12470个负样本对。样本都是随机选择的。为了评价不同头部姿势的影响，我们设定了3个基准：30，60，和90。它们代表了测试数据中，从±30度到±90度的人头部姿势。显然，这3个基准的性能表现不同。

¹⁰<http://gr.xjtu.edu.cn/web/jianyi/english-version>

表 9: 每组相似度分数的平均值(%)

模型	000	001	010	011	100	101	110
unicorn9691	78.07	81.74	79.08	87.96	81.67	82.95	90.27
unicorn9583	76.71	80.96	77.78	87.71	80.61	82.14	89.97
unicorn9490	75.22	79.30	76.39	87.37	79.69	81.66	89.67
unicorn_uc_9132	81.18	84.55	83.75	91.27	84.83	85.95	93.14

表 10: OFID上的验证基准: TAR@FAR=1e-1~ 1e-4

模型	1e-1	1e-2	1e-3	1e-4
unicorn9691	99.97	99.95	99.91	99.80
unicorn9583	99.97	99.94	99.83	99.39
unicorn9490	99.97	99.89	99.45	97.96
unicorn_uc_9132	99.98	99.93	99.75	99.20

表 11: OFVD 的验证基准(从-90 到90): TAR@FAR=1e-1~ 1e-4 和准确率

模型	1e-1	1e-2	1e-3	1e-4	Accuracy
unicorn9699	62.96	09.06	00.00	00.00	N/A
unicorn9691	63.58	09.36	00.00	00.00	79.82
unicorn9583	61.85	07.73	00.00	00.00	78.95
unicorn9490	53.81	09.21	00.00	00.00	76.25
unicorn_uc_9132	59.66	08.09	00.00	00.00	N/A

表 12: OFVD 的验证基准(从-60 到60): TAR@FAR=1e-1~ 1e-4 和准确率

模型	1e-1	1e-2	1e-3	1e-4	准确率
unicorn9699	98.07	08.72	00.00	00.00	94.33
unicorn9691	97.87	09.20	00.00	00.00	94.29
unicorn9583	96.34	09.28	00.00	00.00	93.78
unicorn9490	93.77	09.37	00.00	00.00	93.01
unicorn_uc_9132	93.89	08.43	00.00	00.00	93.88

4.4 正脸-侧脸in-the-Wild 验证

我们搜集了一个新的人脸数据集, 它可以促进从正脸到侧脸验证的研究。这个数据集的目的是剥离姿势变化的因素, 包括极端的姿势如侧脸, 许多的特征都会被遮挡起来。我们称这个数据集为Celebrities in Frontal-Profile(CFP) 数据集。

表 13: OFVD 的验证基准(从-30 到30): TAR@FAR=1e-1~ 1e-4 和准确率

模型	1e-1	1e-2	1e-3	1e-4	准确率
unicorn9699	—	—	—	—	—
unicorn9691	—	—	—	—	—
unicorn9583	—	—	—	—	—
unicorn9490	—	—	—	—	—
unicorn_uc_9132	—	—	—	—	—

5 特殊场景的测试协议

5.1 建筑工地场景

这是我们从KTP中搜集的数据。目前,有20个建筑工地部署了我们的系统。我们选择其中的2处,总共有922个人(只有一些标签为女性)。在一些例子中,它们中的几乎1/9都是身份证照片5.1(a)。每个人都有一张通过USB摄像头拍摄而来的正脸照片5.1(d)。其余的数据是在真实场景中,在正门前通过IP摄像头拍摄而来。年龄跨度为18岁至60岁。在这种情况下,我们只需要1:1的验证。所以我们仅关心正脸。



图 5: KTP 数据样本. (a) 是身份证照片; (b) 和(c) 是从真实场景中记录的照片; (d) 是用USB摄像头采集得来。

由于IP摄像头数据是在户外很长的一个时间跨度内获取,在这类数据中测试就变得很有价值。所以我们在KTP数据集上建立了2个基准:全局样本对和局部样本对。在全局样本对中,我们使用所有的数据,建立了100000/100000个正样本对和负样本对,涵盖所有的人,来评价户外正脸验证的能力。在局部样本对中,我们模拟

表 14: KTP 的验证基准(全局样本对): TAR@FAR=1e-1~ 1e-4 and Accuracy

模型	1e-1	1e-2	1e-3	1e-4	准确率
unicorn9722	96.53	91.92	81.71	53.09	96.07